

ENTREGABLE 3

CUADRO COMPARATIVO DE COSTOS Y MATRIZ DE DECISIÓN ESTRATÉGICA

Sistema inteligente de triage de tickets internos de soporte técnico



OBJETIVO DEL ANÁLISIS

- Comparar tarifas oficiales por millón de tokens y traducirlas a costo estimado por ticket.
- Justificar el uso operativo de DeepSeek Flash frente a alternativas económicas y modelos de mayor capacidad.
- Demostrar escenarios de ahorro iguales o superiores al 50% sin atribuir a Batch una función en tiempo real.
- Explicitar supuestos, límites de tokens, riesgos de variación tarifaria y criterios de decisión.

Tarifas consultadas el 15 de septiembre de 2026 | Valores en USD

Versión 0.1 | Draft para revisión

Conclusión ejecutiva

Decisión recomendada para el workflow implementado

Modelo operativo seleccionado

DeepSeek Flash

Se mantiene como modelo conversacional del AI Agent porque cubre clasificación textual, salida JSON y respuesta síncrona con una API ya operativa. Pro aportaría capacidad excedente para este alcance y no mejora la trazabilidad del proceso.

- Configuración real: deepseek-flash con Max Tokens = 2500.
- La elección se declara como sustitución de los proveedores citados como referencia en la consigna.
- El fundamento principal es adecuación operativa y continuidad de cursada; no se afirma que sea siempre la tarifa mínima.

COSTO TÍPICO OFF-PEAK

USD 0.3750

1.000 tickets/mes

COSTO TÍPICO PEAK

USD 0.7500

1.000 tickets/mes

AHORRO VS GPT-4O

88% a 94%

según franja DeepSeek

LÍMITE DE SALIDA

2500 tokens

techo, no promedio

Tarifas oficiales comparadas

USD por millón de tokens; impuestos, tipo de cambio y cargos de infraestructura excluidos

Modelo	Modalidad	Input / 1M	Output / 1M	Respuesta
DeepSeek Flash	Off-peak, cache miss	0.15	0.60	Síncrono
DeepSeek Flash	Peak, cache miss	0.30	1.20	Síncrono
GPT-4o mini	Estándar	0.15	0.60	Síncrono
GPT-4o mini	Batch, -50%	0.075	0.30	Hasta 24 h
Claude Sonnet 5	Estándar	2.00	10.00	Síncrono
GPT-4o	Estándar	2.50	10.00	Síncrono

Lectura correcta

- La facturación depende de tokens efectivamente procesados.
- Las tarifas DeepSeek cambian entre peak y off-peak.
- Los valores Batch de GPT-4o mini se derivan del descuento oficial del 50%.

Cache y variabilidad

- DeepSeek publica tarifas menores para cache hit.
- El cálculo base usa cache miss para no sobreestimar ahorros.
- Las tarifas deben verificarse nuevamente antes de una proyección contractual.

Fecha de consulta: 15 de septiembre de 2026. Los precios son referencias variables del proveedor, no cotizaciones comerciales garantizadas.

Supuestos y fórmula de cálculo

Escenario reproducible para comparar proveedores con el mismo volumen

Escenario típico mensual

- Volumen: 1.000 tickets por mes.
- Entrada por ticket: 1.500 tokens.
- Salida estructurada por ticket: 250 tokens.
- Entrada incluye prompt, asunto, cuerpo, Nombre y Rol.
- Salida contempla las seis claves del Structured Output Parser.

Escenario de techo

- Se mantienen 1.500 tokens de entrada.
- La salida alcanza el límite completo de 2.500 tokens.
- No representa el uso esperado; funciona como prueba presupuestaria conservadora.
- El límite controla exposición, pero no garantiza consumo constante.

FÓRMULA

$$\text{Costo} = (\text{tokens input} / 1.000.000 \times \text{tarifa input}) + (\text{tokens output} / 1.000.000 \times \text{tarifa output})$$

Costo mensual = costo por ticket x cantidad mensual de tickets

Costo mensual estimado

Escenario típico: 1.000 tickets, 1.500 tokens de entrada y 250 de salida

Costo total mensual



Alternativa	Costo / ticket	Costo / mes	Modalidad
DeepSeek Flash - off-peak	USD 0.000375	USD 0.3750	Síncrono
DeepSeek Flash - peak	USD 0.000750	USD 0.7500	Síncrono
GPT-4o mini - estándar	USD 0.000375	USD 0.3750	Síncrono
GPT-4o mini - Batch	USD 0.000188	USD 0.1875	Asíncrono <=24 h
Claude Sonnet 5	USD 0.005500	USD 5.50	Síncrono
GPT-4o	USD 0.006250	USD 6.25	Síncrono

Resultado: DeepSeek Flash off-peak y GPT-4o mini estándar producen el mismo costo bajo estos supuestos; en peak, DeepSeek conserva amplia ventaja frente a GPT-4o y Claude Sonnet 5.

Sensibilidad al límite de salida

Escenario conservador con 2.500 tokens de output en cada ticket

Costo mensual si todas las respuestas alcanzaran el límite



Alternativa	Típico / mes	Techo / mes	Multiplicador
DeepSeek Flash - off-peak	USD 0.3750	USD 1.72	4.6x
DeepSeek Flash - peak	USD 0.7500	USD 3.45	4.6x
GPT-4o mini - estándar	USD 0.3750	USD 1.72	4.6x
GPT-4o mini - Batch	USD 0.1875	USD 0.8625	4.6x
Claude Sonnet 5	USD 5.50	USD 28.00	5.1x
GPT-4o	USD 6.25	USD 28.75	4.6x

El techo de 2.500 tokens limita una respuesta individual; el costo debe monitorearse con uso real porque la salida JSON esperada es mucho más breve.

Matriz de decisión estratégica

Adecuación cualitativa al triage textual y a la arquitectura implementada

Alternativa	Tiempo real	JSON	Eficiencia	Continuidad	Decisión
DeepSeek Flash	Alta	Alta	Alta	Alta	Seleccionado
GPT-4o mini	Alta	Alta	Alta	Media	Alternativa equivalente
GPT-4o mini Batch	Baja	Alta	Alta	Baja	Solo cargas diferibles
Claude Sonnet 5	Alta	Alta	Baja	Baja	Lectura densa compleja
GPT-4o	Alta	Alta	Baja	Baja	Capacidad excedente

Por qué Flash

- La tarea es clasificación y extracción estructurada de texto.
- No requiere razonamiento extenso ni lectura documental masiva.
- La API paga ya estaba operativa durante la cursada.
- La integración actual evita un cambio de proveedor sin beneficio funcional probado.

Alternativas descartadas

- Claude Sonnet 5 se reserva para lectura densa o tareas de mayor complejidad.
- GPT-4o ofrece capacidad mayor a la necesaria y eleva el costo.
- Batch reduce precio, pero su ventana de hasta 24 horas no sirve para tickets inmediatos.
- DeepSeek Pro no se considera necesario para este nodo.

La decisión combina adecuación técnica, sincronía, acceso API disponible y costo. No se basa exclusivamente en la tarifa nominal.

Ahorro presupuestario

Demostración matemática del umbral del 50% y sus condiciones

DEEPSEEK PEAK VS GPT-4O

88%

USD 0.7500 vs USD 6.25 / mes

mismo volumen típico

DEEPSEEK OFF-PEAK VS GPT-4O

94%

USD 0.3750 vs USD 6.25 / mes

mismo volumen típico

GPT-4O MINI BATCH VS ESTÁNDAR

50%

USD 0.1875 vs USD 0.3750 / mes

mismo volumen típico

Qué queda certificado

- DeepSeek Flash supera el 50% de ahorro frente a GPT-4o incluso en franja peak.
- OpenAI Batch reduce exactamente 50% frente al mismo modelo estándar.
- Los porcentajes dependen del escenario declarado y de tarifas vigentes.

Límite operativo

- Batch no se implementa en el workflow actual.
- Una espera de hasta 24 horas contradice triage, HITL y notificación inmediata.
- El ahorro de Batch es una alternativa documental para procesos masivos diferibles.

Controles de consumo

Medidas implementadas y oportunidades sin rediseñar el workflow

Control	Estado	Efecto económico	Decisión
Max Tokens = 2500	Implementado	Limita salida máxima del modelo	Mantener y monitorear
Structured Output Parser	Implementado	Reduce texto libre y reprocesos	Mantener
Validación previa	Implementado	Evita invocar IA con datos incompletos	Mantener
Anti-duplicación	Implementado	Evita costo por Gmail Message ID repetido	Mantener
Memoria por Thread ID	Implementado	Aporta contexto; puede aumentar entrada	Medir uso real
Prompt más compacto	Oportunidad	Reduce tokens de entrada	Optimizar solo con QA
Batch	No implementado	50% menos, sin respuesta inmediata	No usar en triage vivo

Medición recomendada

- Registrar input_tokens y output_tokens por ejecución si el nodo los expone.
- Comparar promedio, percentil alto y cantidad de reintentos.
- Recalcular presupuesto cuando cambie el prompt o el proveedor.

Regla de gobierno

- No elevar el límite sin evidencia de truncamiento.
- No cambiar de modelo únicamente por una diferencia mínima de precio.
- Repetir QA antes de modificar prompt, parser o modelo.

Riesgos, dependencias y límites

Qué puede alterar el presupuesto y cómo interpretar la estimación

Confirmado

- El JSON final configura deepseek-flash y Max Tokens = 2500.
- La salida esperada contiene seis campos estructurados.
- DeepSeek, OpenAI y Anthropic facturan por tokens.
- OpenAI Batch publica un descuento del 50%.

Supuesto de cálculo

- 1.000 tickets mensuales.
- 1.500 tokens de entrada por ticket.
- 250 tokens de salida típica.
- Sin cache, reintentos, impuestos ni infraestructura.

No verificado

- Promedio real de tokens por ejecución.
- Distribución real entre horarios peak y off-peak.
- Tipo de cambio y carga impositiva aplicable.
- Tasa real de errores o reintentos.

Riesgo residual

- Las tarifas pueden cambiar sin relación con el workflow.
- Una entrada extensa puede elevar el costo aunque la salida sea breve.
- La memoria contextual puede acumular tokens adicionales.
- El endpoint y la disponibilidad del proveedor son dependencias externas.

Trazabilidad contra el criterio

Ubicación de requisitos, fuentes de precios y fecha de consulta

Requisito	Ubicación	Evidencia
Cuadro comparativo de costos	Páginas 3, 5 y 6	Tarifas, escenario típico y techo
Matriz de decisión estratégica	Página 7	Adecuación y descarte
Modelo seleccionado	Páginas 2 y 7	DeepSeek Flash
Modelo económico	Páginas 3 a 5	GPT-4o mini y DeepSeek Flash
Lectura densa	Página 7	Claude Sonnet 5
Procesamiento masivo	Páginas 7 y 8	GPT-4o mini Batch
Ahorro >= 50%	Página 8	Cálculos con igual volumen
Límite de tokens	Páginas 2, 4, 6 y 9	Max Tokens = 2500

Fuentes oficiales

- DeepSeek API Docs - Models & Pricing: https://api-docs.deepseek.com/quick_start/pricing/
- OpenAI API - GPT-4o mini: <https://developers.openai.com/api/docs/models/gpt-4o-mini>
- OpenAI API Reference - Batch: <https://platform.openai.com/docs/api-reference/batch/object>
- OpenAI API - GPT-4o: <https://developers.openai.com/api/docs/models/gpt-4o>
- Anthropic - Claude Sonnet 5: <https://www.anthropic.com/news/claude-sonnet-5>
- Consulta realizada el 15 de septiembre de 2026.