

Justificación del límite de 2.500 tokens

La consigna exige limitar Max Tokens para optimizar el consumo. El valor final no fue seleccionado arbitrariamente.

Durante QA se probaron límites menores que resultaron insuficientes para algunas entradas y outputs estructurados. También se comprobó el funcionamiento sin límite explícito, pero esa opción no cumplía adecuadamente el objetivo documental de establecer un máximo finito.

Se adoptó finalmente 2500, que permitió procesar los casos ensayados manteniendo un límite explícito.

El JSON final confirma deepseek-flash y maxTokens: 2500.